

Projektarbeit Genomik und Phylogenie

Julian Rasp, Raphael Ortner, Johann Vogel

12. April 2026

Inhaltsverzeichnis

1	Einleitung	1
2	Methodik	2
2.1	Homologiesuche	2
2.2	Mathematische Evaluation der Substitutionsmatrizen	2
2.2.1	Divergenzskalierung (Relative Entropie)	2
2.2.2	Art der Matrix (Evolutionsmodell und Zielhäufigkeiten)	2
2.3	Multiples Sequence Alignment (MSA)	3
2.3.1	Alignment-Algorithmus und Parameter	3
2.3.2	Visualisierung und quantitative Analyse	3
2.4	Phylogenetische Baum Rekonstruktion	4
2.4.1	Distanzmatrix und Heatmap	4
2.4.2	Strikte und nicht-strikte Ultrametrie	4
2.4.3	Four-Point-Condition	4
2.4.4	Delta-Plot	4
2.4.5	Robustheit und cophenetische Korrelation	5
2.4.6	Grundlagen der verwendeten Clustering-Verfahren	5
3	Ergebnisse	6
3.1	Datenbank-Annotation und Charakterisierung des Suchraums	6
3.2	Divergenzskalierung und Informationsdichte	6
3.3	Validierung des Evolutionsmodells	7
3.4	Globale Alignment-Statistik	8
3.5	Domänenspezifische Struktur- und Sequenzkorrelation	8
3.6	Phylogenetische Struktur der TSR3-Homologen	10
3.6.1	Heatmap	10
3.6.2	Ultrametrie	11
3.6.3	Four-Point-Condition und Delta-Plot	11
3.6.4	Cophenetische Korrelation und Robustheit	11
3.6.5	Phylogenetische Bäume im Vergleich	12
4	Diskussion	13
4.1	Interpretation der Modellevaluation: Skalierung und Evolutionsmodell	13
4.2	Kritische Reflexion der Methodik und akademischen Praxis	13
4.3	Methodenkritik: Performance des ClustalW-Algorithmus	14
4.4	Biologische Implikation: Die Rolle intrinsisch ungeordneter Regionen (IDRs)	14
4.5	Phylogenetische Analyse der TSR3-Homologen	15

5	Anhang	17
5.1	Farbkodierung und Histogramm der Heatmap	17
5.2	Überprüfung der Ultrametrie und Four-Point-Condition mit allen getesteten Toleranzen	17
5.3	Delta-Plot	18
5.4	Werte für Robustheit und cophenetische Korrelation	18
5.5	Pylogenetische Bäume verschiedener Clustering Methoden	19
5.5.1	UPGMA	19
5.5.2	WPGMA	20
5.5.3	WARD	21
5.5.4	Visueller Vergleich ausgewählter Methoden	22

1 Einleitung

Die präzise Reifung von Ribosomen ist ein fundamentaler und evolutionär hochgradig konservierter Prozess in allen Domänen des Lebens. In Eukaryoten erfordert die Biogenese der ribosomalen Untereinheiten ein komplexes Netzwerk aus über 200 Akzessorproteinen [1]. Ein zentraler Akteur in diesem Gefüge ist das Protein Twenty-two-S RNA-reducing protein 3 oder kurz TSR3, welches für die essentielle Modifikation der 18S rRNA verantwortlich ist.

Für die phylogenetische Rekonstruktion stellt TSR3 ein ideales Modellsystem dar. Als unerlässliches Enzym der Ribosomenbiogenese unterliegt sein katalytischer Kern einem starken selektiven Druck, was die Identifizierung von Orthologen über weite evolutionäre Distanzen hinweg ermöglicht. Zugleich weist TSR3 einen bipolaren strukturellen Aufbau auf: Neben der hochstrukturierten katalytischen Domäne besitzt es intrinsisch ungeordnete Regionen (Intrinsically Disordered Regions, IDRs). Da für letztere keine starre 3D-Faltung zwingend ist, akkumulieren sie Mutationen mit einer deutlich höheren Rate als die funktionellen Zentren. Diese Kombination aus extremer Konservierung und lokaler Sequenzvariabilität erlaubt es, Verwandtschaftsverhältnisse sowohl auf makro- als auch auf mikroevolutionärer Ebene präzise abzubilden.

Um die evolutionäre Historie sowie die strukturelle Organisation von TSR3 zu entschlüsseln, ist der folgende Bericht in drei wesentliche Analyseschritte gegliedert. Den Ausgangspunkt bildet die Identifikation orthologer Sequenzen mittels BLASTp. Auch wenn dieser Schritt in der Praxis häufig vernachlässigt wird, soll dieser Bericht einen systematisch begründeten und wissenschaftlich reflektierten Ansatz zur Wahl der Substitutionsmatrix aufzeigen. Durch die Auseinandersetzung mit den methodischen Grundlagen wird deutlich gemacht, dass die Qualität dieser Auswahl maßgeblich über die Aussagekraft sämtlicher nachgelagerter Analysen entscheidet. Darauf aufbauend wird ein Multiples Sequenzalignment (MSA) der engsten Verwandten generiert. Die statistische Auswertung dieses Alignments ermöglicht es, die funktionelle Dichotomie zwischen dem katalytischen Kern und der IDR auf Sequenzebene messbar zu machen. Abschließend münden diese Daten in eine phylogenetische Rekonstruktion. Durch die vergleichende Anwendung distanzbasierter Clustering-Verfahren (wie Neighbor-Joining und UPGMA) wird die Konsistenz der evolutionären Hierarchien überprüft, um ein robustes Bild der Phylogenie von TSR3 zu zeichnen.

2 Methodik

2.1 Homologiesuche

Die Identifikation homologer Sequenzen wurde mittels des Algorithmus BLASTP (Basic Local Alignment Search Tool für Proteine der National Center for Biotechnology Information, Version 2.12.0+) durchgeführt. Als Query-Sequenz diente eine initial uncharakterisierte Aminosäuresequenz mit einer Länge von 312 Aminosäuren. Die Suche erfolgte gegen eine unbenannte lokale Datenbank bestehend aus 538 Einträgen, woraus 501 signifikante BLAST-Hits resultierten. Für die nachfolgenden Analysen, einschließlich des Multiplen Sequenzalignments (MSA) und der phylogenetischen Baumrekonstruktion, wurden ausschließlich die 30 Treffer mit dem höchsten Bit-Score (Top-30-Hits) extrahiert.

2.2 Mathematische Evaluation der Substitutionsmatrizen

Um eine fundierte Auswahl der optimalen Substitutionsmatrix für das vorliegende Protein zu gewährleisten und Verzerrungen in Folgeanalysen zu vermeiden, wurde die Matrizen-evaluation in zwei voneinander als unabhängig angenommenen Dimensionen unterteilt: die Skalierung der Divergenz ("Strenge" der Matrix) und das zugrunde liegende Evolutionsmodell (PAM oder BLOSUM). Untersucht wurden ausgewählte in BLASTP zu Verfügung stehende Matrizen (BLOSUM-62, 80, 90 sowie PAM-70 und 30)

2.2.1 Divergenzskalierung (Relative Entropie)

Zur Bestimmung der optimalen Strenge der Matrix wurde die relative Entropie (H) als Maß für den Informationsgehalt des Alignments herangezogen. Die theoretische Entropie einer Matrix gibt an, wie viel Information (in Bits) pro Position im Alignment erwartet wird. Sie berechnet sich nach dem Log-Odds-Modell als:

$$H_{theo} = \sum_{i,j} q_{ij} \log_2 \left(\frac{q_{ij}}{p_i p_j} \right) / \lambda = \sum_{i,j} q_{ij} S_{ij} \quad (1)$$

Hierbei beschreibt q_{ij} die theoretische Zielhäufigkeit (die Wahrscheinlichkeit, dass die Aminosäuren i und j evolutionär voneinander abstammen) und $p_i p_j$ die Hintergrundwahrscheinlichkeit des zufälligen gemeinsamen Auftretens. Der Parameter λ dient als Skalierungsfaktor und S_{ij} ist der entsprechende Matrix-Score.

Diese theoretische Erwartung (H_{theo}) wurde mit der tatsächlich beobachteten Entropie (H_{obs}) abgeglichen. Letztere ergibt sich näherungsweise aus dem durchschnittlichen Bit-Score (s) pro Alignment-Länge (L). Die Entropie gibt somit für ein lokales Alignment zwei vergleichbare Werte für den erwarteten Score pro Aminosäure an. Eine hohe Übereinstimmung zwischen theoretischer und beobachteter Entropie indiziert eine optimale Passform des Modells.

2.2.2 Art der Matrix (Evolutionsmodell und Zielhäufigkeiten)

Zur Differenzierung zwischen blockbasierten Modellen (BLOSUM) und Modellen basierend auf zeitkontinuierlichen Markov-Prozessen (PAM) wurden die empirischen Zielhäufigkeiten (q_{ij}^{obs}) der Aminosäuresubstitutionen evaluiert. Diese wurden jeweils aus dem MSA der Top-30-Hits und gesamten 501-Hits berechnet. Die empirische Häufigkeit des Austauschs zweier Aminosäuren i und j ist definiert durch:

$$q_{ij}^{obs} = \frac{C_{ij}}{\sum_{k=1}^{20} \sum_{l=1}^{20} C_{kl}} \quad (2)$$

wobei C_{ij} die Zählrate der Aminosäurepaarungen über alle validen MSA-Spalten c darstellt. Zur algorithmischen Skalierung für das 501-Sequenzen-MSA wurde die Zählung von einer quadratischen Paar-Iteration mit der R `combn()` Funktion ($\mathcal{O}(N^2)$) auf eine effiziente Matrixoperation

($\mathcal{O}(N)$) optimiert. Die Elemente von C_{ij} berechnen sich pro Spalte aus dem äußeren Produkt der spaltenspezifischen Aminosäure-Häufigkeitsvektoren $v^{(c)}$. Mathematisch ergibt sich dabei $v_i^{(c)} \cdot v_j^{(c)}$ für $i \neq j$, während die Diagonale zur Vermeidung unmöglicher Selbstpaarungen als $v_i^{(c)}(v_i^{(c)} - 1)$ definiert ist. Aus diesen Frequenzen wurden die beobachteten Log-Odds-Scores (S_{ij}^{obs}) unter Berücksichtigung der empirischen Hintergrundhäufigkeiten (p_i^{obs}) abgeleitet:

$$S_{ij}^{obs} = \log_2 \left(\frac{q_{ij}^{obs}}{p_i^{obs} \cdot p_j^{obs}} \right) \quad (3)$$

Die Übereinstimmung der etablierten theoretischen Matrizenmodelle (S^{theo}) mit den biologischen Daten (S^{obs}) wurde abschließend mittels der Pearson-Korrelation (R) ermittelt:

$$R = \frac{\sum (S_{ij}^{theo} - \overline{S^{theo}}) (S_{ij}^{obs} - \overline{S^{obs}})}{\sqrt{\sum (S_{ij}^{theo} - \overline{S^{theo}})^2 \sum (S_{ij}^{obs} - \overline{S^{obs}})^2}} \quad (4)$$

Die Analyse wurde sowohl für die Top-30-Hits als auch für den globalen Datensatz (501 Hits) durchgeführt. Um einen methodischen Zirkelschluss bei der Evaluierung der Neutralen-Hypothese zu vermeiden, wurden das zugrunde liegende BLAST-Suchverfahren sowie das Multiple Sequenzalignment zum Vergleich unter einer BLOSUM-Hypothese generiert, was bedeutet, dass dafür ausschließlich BLOSUM Matrizen verwendet wurden.

2.3 Multibles Sequence Alignment (MSA)

Für die phylogenetische Analyse wurden die 30 besten Treffer aus der vorangegangenen BLASTp-Suche ausgewählt. Die entsprechenden Proteinsequenzen wurden im FASTA-Format aus der bereitgestellten Datenbank extrahiert. Um die Lesbarkeit und Auswertbarkeit zu gewährleisten, wurden die Sequenz-IDs vor dem Alignment angepasst. Die Benennung folgte der binominalen Nomenklatur, ergänzt um die jeweilige Accession-ID, um Eindeutigkeit bei möglichen Duplikaten zu garantieren.

2.3.1 Alignment-Algorithmus und Parameter

Das Multiple Sequence Alignment wurde in der Softwareumgebung R (Version 4.5.2) durchgeführt. Zur Berechnung wurde das Paket `msa` verwendet. Dabei wurde der ClustalW-Algorithmus gewählt. Die Bewertung des Aminosäureaustausches durch Substitutionsmatrizen wurde im Algorithmus auf PAM beschränkt, die aus der im BLAST-Schritt ermittelte Sequenzidentität abgeleitet war.

2.3.2 Visualisierung und quantitative Analyse

Zur Visualisierung des Alignments wurde das R-Paket `ggmsa` eingesetzt, wobei das Farbschema `Chemistry_AA` zur Kennzeichnung chemischer Eigenschaften der Aminosäuren verwendet wurde. Zusätzlich zur visuellen Darstellung wurde eine quantitative Konservierungsanalyse erstellt. Diese weist einerseits die Konservierungsrate auf, also den Anteil der am häufigsten vorkommenden Aminosäure pro Alignment-Spalte, und berechnet andererseits eine Gap-Frequenz, welche den Anteil der Lücken pro Position angibt. Mittels dieser Informationen lassen sich Regionen mit hoher Variabilität oder Sequenzverlusten identifizieren.

Diese räumlichen Informationen wurden mit denen einer Strukturvorhersage für die Query Sequence aus AlphaFold (*Monomer Version 2.0*) verglichen. Damit konnten bekannte funktionelle Domänen über eine Mapping-Funktion auf die Alignment-Koordinaten übertragen werden, um Statistiken zu den Domänen auszuwerten.

2.4 Phylogenetische Baum Rekonstruktion

2.4.1 Distanzmatrix und Heatmap

Für jedes Sequenzpaar i, j wurde eine evolutionäre Distanz d_{ij} aus dem MSA bestimmt. Formal kann diese als Anteil voneinander abweichender Aminosäuren an allen vergleichbaren Positionen beschrieben werden:

$$d_{ij} = \frac{n_{\text{Unterschiede}}}{n_{\text{verglichene Positionen}}} \quad (5)$$

Die Gesamtheit aller paarweisen Distanzen bildet die Distanzmatrix $D = (d_{ij})$, welche die Grundlage aller weiteren phylogenetischen Auswertungen darstellt. Zur genaueren Analyse wurde diese Matrix als Heatmap visualisiert. Dabei entsprechen kleine Distanzwerte hoher Sequenzähnlichkeit, größere Werte hingegen stärkerer evolutionärer Divergenz. Cluster eng verwandter Arten zeigen sich in dieser Darstellung als blockartige Strukturen entlang der Hauptdiagonalen.

2.4.2 Strikte und nicht-strikte Ultrametrie

Da einige hierarchische Clustering-Verfahren, insbesondere UPGMA und WPGMA, eine ultrametrische Distanzstruktur voraussetzen, wurde die Matrix auf diese Eigenschaft hin geprüft. Für drei Taxa x, y, z liegt strikte Ultrametrie vor, wenn die beiden größten Distanzen identisch sind und strikt größer als die dritte:

$$d_{\max 1} = d_{\max 2} > d_{\min} \quad (6)$$

Nicht-strikte Ultrametrie erlaubt zusätzlich den Fall vollständiger Gleichheit:

$$d_{\max 1} = d_{\max 2} \geq d_{\min} \quad (7)$$

Biologisch entspricht Ultrametrie der Annahme einer konstanten Evolutionsrate entlang aller Linien. Eine Verletzung dieser Bedingung spricht somit gegen die Molekulare-Uhr-Hypothese im Datensatz.

2.4.3 Four-Point-Condition

Zur Beurteilung, ob sich die Distanzmatrix konsistent durch einen gewichteten phylogenetischen Baum darstellen lässt, wurde die Four-Point-Condition untersucht. Für vier Taxa a, b, c, d wurden die drei Summen

$$S_1 = d(a, b) + d(c, d); \quad S_2 = d(a, c) + d(b, d); \quad S_3 = d(a, d) + d(b, c) \quad (8)$$

berechnet. Eine Distanzmatrix ist additiv, wenn die beiden größten dieser drei Werte gleich sind und mindestens so groß wie die dritte. Die Four-Point-Condition dient damit als zentrales Kriterium für die Baumartigkeit der Daten.

2.4.4 Delta-Plot

Ergänzend zur Four-Point-Condition wurde die Abweichung der Distanzmatrix von einer ideal baumartigen Struktur über einen Delta-Plot charakterisiert. Für jedes Quartett wurde dazu ein Delta-Wert

$$\delta = \frac{S_{\max} - S_{\text{mittel}}}{S_{\max} - S_{\min}} \quad (9)$$

bestimmt. Werte nahe 0 sprechen für eine ausgeprägt baumartige Struktur, während größere Werte auf widersprüchliche Signale hinweisen.

2.4.5 Robustheit und cophenetische Korrelation

Zur ergänzenden Bewertung der rekonstruierten Bäume wurde zudem auch ihre Robustheit untersucht. Dabei wurde geprüft, ob die maximale Abweichung zwischen der ursprünglichen Distanzmatrix und den cophenetischen Distanzen des Baumes im Verhältnis zur kleinsten inneren Astlänge klein genug bleibt, damit die innere Baumstruktur als stabil angesehen werden kann. Formal wurde dazu die maximale absolute Differenz

$$\|M' - M\|_N = \max_{i,j} |c_{ij} - d_{ij}| \quad (10)$$

bestimmt und mit der kleinsten inneren Astlänge w_0 des jeweiligen Baumes ins Verhältnis gesetzte. Ein Baum gilt dabei nur dann als robust, wenn dieses Verhältnis klein genug ist. Auf diese Weise lässt sich beurteilen, ob die innere Verzweigungsstruktur gegenüber kleinen Distanzfehlern stabil ist oder bereits durch geringe Abweichungen verändert werden könnte.

Zusätzlich wurde zur Bewertung, wie gut ein rekonstruierter Baum die ursprüngliche Distanzmatrix insgesamt repräsentiert, die cophenetische Korrelation berechnet. Diese vergleicht die paarweisen Originaldistanzen d_{ij} mit den cophenetischen Distanzen c_{ij} des jeweiligen Baumes:

$$r_c = \frac{\sum (d_{ij} - \bar{d})(c_{ij} - \bar{c})}{\sqrt{\sum (d_{ij} - \bar{d})^2 \sum (c_{ij} - \bar{c})^2}} \quad (11)$$

Ein hoher Wert von r_c zeigt an, dass die Baumtopologie die Distanzstruktur des Datensatzes gut widerspiegelt.

2.4.6 Grundlagen der verwendeten Clustering-Verfahren

Zur Rekonstruktion der Verwandtschaftsverhältnisse wurden mehrere distanzbasierte Verfahren verglichen. Dabei bezeichnen A , B und C jeweils Cluster, also Gruppen bereits zusammengefasster Taxa. Die Größen $|A|$ und $|B|$ geben die Anzahl der Elemente in den Clustern an.

Neighbor Joining (NJ). Neighbor Joining rekonstruiert einen ungewurzelten Baum und benötigt keine Ultrametrie. Das Verfahren wählt in jedem Schritt dasjenige Taxonpaar, für das der Eintrag der Q -Matrix minimal ist:

$$Q(i, j) = (n - 2)d(i, j) - \sum_k d(i, k) - \sum_k d(j, k) \quad (12)$$

Da NJ keine konstante Evolutionsrate voraussetzt, ist das Verfahren für Datensätze mit heterogenen Linienlängen besonders geeignet.

UPGMA. UPGMA erzeugt einen gewurzelten Baum durch sukzessives Zusammenfassen der ähnlichsten Cluster. Der Abstand eines neu gebildeten Clusters $A \cup B$ zu einem weiteren Cluster C ergibt sich als größengewichtetes Mittel:

$$d(A \cup B, C) = \frac{|A|d(A, C) + |B|d(B, C)}{|A| + |B|} \quad (13)$$

UPGMA setzt eine ultrametrische Distanzstruktur voraus.

WPGMA. WPGMA ist eng mit UPGMA verwandt, gewichtet jedoch beide zu vereinigenden Cluster unabhängig von ihrer Größe gleich:

$$d(A \cup B, C) = \frac{d(A, C) + d(B, C)}{2} \quad (14)$$

Ward-Methode. Die Ward-Methode basiert auf der Minimierung der Zunahme der inneren Varianz beim Zusammenschluss zweier Cluster. Dazu wird die Änderung der Fehlerquadratsumme betrachtet:

$$\Delta ESS = \sum (x_i - \bar{x})^2 \quad (15)$$

Hierbei bezeichnet *ESS* (*Error Sum of Squares*) die Summe der quadrierten Abweichungen aller Beobachtungen x_i vom jeweiligen Cluster-Mittelwert $\bar{x}$. Die Größe ΔESS gibt an, um wie viel die innere Streuung beim Zusammenschluss zweier Cluster zunimmt. In jedem Schritt wird diejenige Fusion gewählt, für die diese Zunahme minimal bleibt. Dadurch entstehen in der Regel kompakte und intern relativ homogene Cluster.

3 Ergebnisse

3.1 Datenbank-Annotation und Charakterisierung des Suchraums

Anhand spezifischer Metadaten der ausgegebenen Treffer lässt sich stark ableiten, dass die unbekannte zugrunde liegende Datenbank auf einem Extrakt der OrthoDB basiert. Ausschlaggebend hierfür waren die Präsenz eindeutiger Orthologous Group Identifiers (OG-IDs, z. B. xxxxxx at7742), OrthoDB-spezifische level_taxid-Tags, das JSON-Metadatenformat sowie eine taxonomische Vorselektion, die charakteristisch für OrthoDB-Exporte ist. Diese Indizien stützen die grundlegende Annahme, dass der vorgegebene Suchraum bereits für orthologe Sequenzen angereichert ist. Dennoch schließt diese Vorselektion das Vorhandensein von In-Paralogen nicht zwingend aus, weshalb eine spätere phylogenetische Baumanalyse zur finalen Differenzierung unerlässlich bleibt. Das Query konnte als die TSR3-Sequenz des Menschen identifiziert werden. Ein erster Vergleich der Basisparameter für die zu untersuchenden Orthologe (Top-30-Hits) offenbarte eine durchgehend hohe und über verschiedene Substitutionsmatrizen hinweg konstante Sequenzidentität von durchschnittlich 85,56 % mit einer Standardabweichung von $\approx 0,04$ % zwischen allen Untersuchten Matrizen. Im Gegensatz dazu variierten die resultierenden durchschnittlichen Bit-Scores (S') signifikant: Während die Standardmatrix BLOSUM62 einen mittleren Bit-Score von 516,24 lieferte, erzielten theoretisch strengere Matrizen wie BLOSUM90 (541,24) und PAM30 (541,45) deutlich höhere Nominalwerte.

3.2 Divergenzskalierung und Informationsdichte

Um zu validieren, ob die höheren Bit-Scores von PAM30 und BLOSUM90 tatsächlich auf einer besseren Modellpassform beruhen oder lediglich Artefakte einer zu harten Bestrafung (Overfitting) darstellen, wurde die relative Entropie analysiert (Zusammenfassung in Tabelle 1). Es zeigte sich eine deutliche Diskrepanz bei den Extremwerten: Am Beispiel der Top-30 weist die Standardmatrix BLOSUM62 ein massives Under-fitting auf. Ihre theoretische Erwartung ($H_{theo} \approx 0,7$ Bits) wird von der beobachteten Informationsdichte der hoch konservierten TSR3-Orthologe ($H_{obs} \approx 1,6$ Bits) weit übertroffen. PAM30 hingegen resultiert in einem deutlichen Overfitting ($H_{theo} \approx 2,57$ Bits vs. $H_{obs} \approx 1,7$ Bits), da das Modell nahezu identische Sequenzen erwartet und die real vorhandenen Variationen zu stark bestraft. Die Matrizen PAM70 und BLOSUM90 trafen hingegen für alle Messungen die empirische Mitte.

Matrix	H_{theo}	Beobachtete Entropie					
		Top-30	ΔH	Top-100	ΔH	Global	ΔH
PAM30	2.57	1.74	−0.83	1.59	−0.98	1.38	−1.19
PAM70	1.60	1.71	0.11	1.56	−0.04	1.36	−0.24
BLOSUM90	1.18	1.74	0.56	1.60	0.42	1.38	0.20
BLOSUM80	0.99	1.74	0.75	1.59	0.60	1.38	0.39
BLOSUM62	0.70	1.66	0.96	1.52	0.82	1.33	0.63

Tabelle 1: Abweichung der beobachteten Entropie von der theoretischen Erwartung (H_{theo}), mit genauen Literatur werten aus [2] Altschul SF. Positive ΔH -Werte (Blau) zeigen eine höhere Informationsdichte als theoretisch erwartet, negative Werte eine geringere (Rot).

3.3 Validierung des Evolutionsmodells

Zur finalen Differenzierung zwischen den Modellen PAM70 und BLOSUM90 wurden die Zielhäufigkeiten mittels Pearson-Korrelation (R) ausgewertet. Wie Tabelle 2 zeigt, erzielten die auf zeitkontinuierlichen Markov-Prozessen basierenden PAM-Matrizen für die hochkonservierten Top-30-Orthologe konsistent die höchsten Werte – sowohl unter einer neutralen dynamischen Alignment-Hypothese (H_{Neutral}) als auch unter der H_{BLOSUM} -Restriktion. Sie übertrafen die blockbasierten Modelle (z. B. BLOSUM90) deutlich. Bei Ausweitung auf den diverseren globalen Datensatz ($N = 501$) zeigte sich eine signifikante Verschiebung der relativen Modellstärke: Während das Kurzzeit-Modell PAM30 bei zunehmender Divergenz nur moderat skalierte ($R = 0,859$) und fast auf das Niveau von BLOSUM90 zurückfiel, stellt PAM70 mit $R = 0,877$ auch hier den globalen Bestwert.

Die Korrelationsanalyse des PAM70-Modells (dargestellt in Abbildung 1) offenbart die spezifischen, vom globalen Trend abweichende Substitutionsmuster. Bei den dargestellten Top-5 am meisten abweichenden Austausch weisen spezifische Tyrosin-Kombinationen (Y-N, Y-A, Y-T) stark negative Residuen auf (Abweichungen < -3). Sie treten im MSA-Datensatz deutlich seltener auf, als es die theoretischen Log-Odds erwarten lassen. Andererseits werden theoretisch extrem stark bestrafte, radikale Substitutionen wie Y-P und W-E (theoretische Log-Odds von -9 respektive -11) in der evolutionären Realität unerwartet häufig toleriert, was sich in starken positiven Residuen ($> +3, 2$) äußert. Ein Abgleich mit den Hintergrundfrequenzen bestätigte, dass diese Anomalien nicht auf eine verzerrte globale Aminosäurezusammensetzung des Proteins zurückzuführen sind. So erreichte die absolute Differenz zwischen den beobachteten Frequenzen im TSR3-Alignment und dem statistischen Standardmodell für alle beteiligten Aminosäuren maximal 3,5% (für Glutaminsäure).

Evolutionmodell	$R_{H_{\text{Neutral}}} \text{ (Top-30)}$	$R_{H_{\text{BLOSUM}}} \text{ (Top-30)}$	$R_{H_{\text{BLOSUM}}} \text{ (Global, } N = 501)$
PAM70	0,855	0,846	0,877
PAM30	0,856	0,841	0,859
BLOSUM90	0,831	0,835	0,857
BLOSUM80	0,831	0,834	0,857
BLOSUM62	0,822	0,823	0,843

Tabelle 2: Pearson-Korrelationskoeffizienten (R) zwischen theoretischen und empirischen Log-Odds-Scores. Die Alignments basieren entweder auf einer Neutralen Hypothese (H_{Neutral}) mit dynamischer Matrixwahl des ClustalW Algorithmus oder rein auf einer BLOSUM Hypothese (H_{BLOSUM}) die Alignments auf Blast ergebnisse mit BLOSUM und ClustalW auf ausschließlich Blosom Matrizen beschränkt.

Korrelation zwischen Zielhäufigkeiten und der Matrix: PAM70

Pearson R = 0.8765 | Top 5 Ausreißer (Residuen) markiert




Abbildung 1: Korrelation der empirischen Log-Odds-Scores (S^{obs}) des globalen Datensatzes unter H_{BLOSUM} mit den theoretischen Log-Odds (S^{theo}) der PAM70-Matrix. Die 5 größten Abweichungen sind mit dem entsprechenden Aminosäure Austausch Beschriftet.

3.4 Globale Alignment-Statistik

Das durchgeführte Multiple Sequence Alignment (MSA) der 30 homologen Proteinsequenzen zeigt eine ausgeprägte globale Homologie. Die quantitative Auswertung über das gesamte Alignment hinweg liefert eine durchschnittliche Konservierung von **72,26 %** bei einer mittleren Gap-Rate von **17,99 %**. Diese Werte deuten auf eine generelle strukturelle und funktionelle Verwandtschaft der Sequenzen hin, offenbaren jedoch bei genauerer Betrachtung eine starke positionsabhängige Variabilität.


3.5 Domänenspezifische Struktur- und Sequenzkorrelation

Durch das Mapping der Referenzsequenz (dem Query: *Homo sapiens* TSR3, [3]) auf die Alignment-Koordinaten konnte das Protein stochastisch in zwei grundlegend verschiedene funktionelle Einheiten unterteilt werden. Diese mathematisch erfassbare Dichotomie korreliert sichtbar stark mit den strukturellen Vorhersagen des AlphaFold-Modells (vgl. Abbildung 2).


Die katalytische Ribosom-Biogenese-Domäne (Position 96–222): Dieser zentrale Bereich bildet den hochstrukturierten Kern des Enzyms. Mit einer relativen Konservierung von **95,33 %** und einer Gap-Rate von exakt **0,00 %** unterliegt dieser Abschnitt einem extremen evolutionären Zwang. Die absolute Intoleranz für Gaps in diesem Bereich belegt die essenzielle funktionelle Bedeutung der Domäne, in welcher der Kofaktor S-Adenosylmethionin (SAM) sowie die Ziel-RNA (18S rRNA) interagieren [1]. Diese hohe Sequenzkonservierung spiegelt sich direkt im

MSA Konservierungs- und Gap-Profil von TSR3

Gesamt-Konservierung: 72.3% | Ribosom-Domäne: 95.3% | Disordered (Gesamt): 64.3%



(a) Sequenzalignment-Profil. Regionen aus dem AlphaFold 3D-Strukturmodell sind farbig markiert (Orange: Disordered Region; Grün: Biogenesis-Domäne).



(b) 3D-Struktur des Homo sapiens TSR3 (AlphaFold). Funktionelle Domänen sind analog markiert (Orange: Disordered Region; Grün: Biogenesis-Domäne).

Abbildung 2: Vergleich von Struktur und Sequenz-Konservierung. Die farblich hervorgehobenen Regionen verdeutlichen die Korrelation zwischen funktionellen Domänen und mathematisch erfassbaren Konservierungsprofilen.

AlphaFold-Strukturmodell wider, welches für diese Domäne Konfidenzwerte (pLDDT) von durchgehend > 90 („Very High“) ausweist. Dies verdeutlicht, dass sich dieser evolutionär konservierte Bereich sehr gut und reproduzierbar in eine kompakte, stabile Tertiärstruktur faltet (sichtbar als grüne Domäne in Abbildung 2b).

Die unstrukturierte C- & N-terminale Region (Positionen 1–21 & 224–312): Im starken Kontrast zur katalytischen Domäne weisen die Termini eine signifikant reduzierte Konservierung von **62,35 %** und eine stark erhöhte Gap-Frequenz von **22,29 %** auf. Strukturbiologisch repräsentiert diese Region eine *Intrinsically Disordered Region* (IDR). Dies wird durch das AlphaFold-Modell untermauert, das diesem Bereich Konfidenzwerte (pLDDT) von < 50 („Very Low“) zuweist. Wie in Abbildung 2b ersichtlich, nimmt diese Region keine definierte räumliche Faltung ein. Das Fehlen einer zwingenden, starren Tertiärstruktur erklärt die stochastischen MSA-Ergebnisse: In diesem biologischen Freiraum können Mutationen und Sequenzverluste (Gaps) im Laufe der Evolution akkumulieren, da sie die prinzipielle katalytische Funktionalität des Proteins nicht gefährden.

3.6 Phylogenetische Struktur der TSR3-Homologen

3.6.1 Heatmap




Abbildung 3: Darstellung der Distanzmatrix als Heatmap

Entlang der Hauptdiagonalen, der Heatmap, sind mehrere kompakte Blöcke erkennbar, die Gruppen eng verwandter Arten markieren. Besonders auffällig sind zusammenhängende Bereiche innerhalb der Primaten, der Nager, der Paarhufer einschließlich walverwandter Arten sowie der Raubtiere und Flossenfüßler. Die Heatmap liefert damit bereits vor der eigentlichen Baumrekonstruktion klare Gruppen, die später auch im phylogenetischen Baum wieder auftauchen (s. Abb. 3).

Zugleich fällt auf, dass die paarweisen Distanzen insgesamt relativ klein bleiben. Der Wertebereich erstreckt sich nur bis ungefähr 0.2, wobei der Großteil der Vergleiche im Bereich zwischen etwa 0.125 und 0.2 liegt (vgl. Anhang Abb. 5). Trotz dieser geringen absoluten Unterschiede

zeigt sich, dass einzelne Taxa, insbesondere das Pferd, innerhalb der Matrix randständig als andere Arten wirken, was auf größere Distanzen zu benachbarten Gruppen hindeutet.

3.6.2 Ultrametrie

Die Prüfung auf strikte Ultrametrie mit verschiedenen Toleranzwerten zeigte, dass die Distanzmatrix diese Bedingung nicht erfüllt. Zahlreichen Triplets verletzen die Bedingung, sodass die Molekulare-Uhr-Annahme für den vorliegenden Datensatz nicht gegeben ist. Auch die nicht-strikte Ultrametrie war nur bei sehr hoher Toleranz gegeben.

Toleranz	Verletzungen strikt	Verletzungsrate strikt	Verletzungen nicht-strikt	Verletzungsrate nicht-strikt
0.1	11	0.27%	0	0%
0.03	240	5.91%	230	5.67%
0.02	713	17.56%	703	17.32%
0.01	1883	46.38%	1875	46.18%

Tabelle 3: Ergebnisse des Ultrametrie-Tests (vollständige Tabelle s. Anhang Tab. 5)

3.6.3 Four-Point-Condition und Delta-Plot

Im Gegensatz zur Ultrametrie fiel die Prüfung der Four-Point-Condition deutlich günstiger aus. Der überwiegende Teil der untersuchten Quartette erfüllte die Bedingung nahezu bei geringeren Toleranzwerten als zuvor bei der Ultrametrie, sodass die Distanzmatrix insgesamt als weitgehend additiv einzustufen ist. Damit liegt eine solide Grundlage für eine baumbasierte Rekonstruktion vor.

Toleranz	Verletzungen	Verletzungsrate
0.01	9307	33.96%
0.02	2741	10.00%
0.04	364	1.33%
0.06	63	0.23%
0.1	0	0%

Tabelle 4: Ergebnisse des Four-Point-Condition-Tests (vollständige Tabelle s. Anhang Tab. 6)

Der Delta-Plot (siehe Anhang Abb. 6) bestätigt die Resultate der Four-Point-Analyse. Die meisten Delta-Werte liegen im niedrigen Bereich nahe Null. Damit zeigen die Daten nur geringe Abweichungen von einer ideal baumartigen Struktur. Diese Ergebnisse ist insbesondere deshalb relevant, weil es die Interpretation der später rekonstruierten Bäume etwas absichert, da die rekonstruierten Topologien somit, mit relativ hoher Wahrscheinlichkeit, nicht bloß methodische Artefakte darstellen.

3.6.4 Cophenetische Korrelation und Robustheit

Die Berechnung der cophenetischen Korrelation (siehe Anhang Tabelle 7) zeigte, dass der Neighbor-Joining-Baum die höchste Übereinstimmung mit der ursprünglichen Distanzmatrix erreicht. Damit bildet dieses Verfahren die paarweisen Distanzverhältnisse am präzisesten ab. Die Ward-Methode erreichte ebenfalls vergleichsweise hohe Werte, während UPGMA und WPGMA geringere Übereinstimmungen zeigten.

Die Robustheitsanalyse ergab jedoch, dass keiner der rekonstruierten Bäume das Robustheitskriterium erfüllt (vgl. Anhang Tabelle 7). In allen Fällen überschritt die maximale Abweichung zwischen ursprünglicher Distanzmatrix und cophenetischer Distanzmatrix den zulässigen Schwellenwert, in unserem Fall also für eine selbst gewählte Grenze von $\rho = 0.5$, relativ zur kleinsten

inneren Astlänge. Im Vergleich der jeweiligen Verhältnisse (est_ratios) schnitt jedoch WPGMA am besten ab gefolgt von Neighbor-Joining.

Der Neighbor-Joining-Baum bleibt dennoch das zuverlässigste Verfahren im Vergleich, da er trotz fehlender formaler Robustheit im Vergleich der est_ratios als zweit bester abschneidet, die höchste cophenetische Korrelation hat und zudem die biologisch plausibelste Topologie aufweist.

3.6.5 Phylogenetische Bäume im Vergleich

Die rekonstruierten Bäume unterscheiden sich zwar in ihrer Feinstruktur aber dennoch gibt es eine, über alle Methoden hinweg, konsistente grobe Struktur, wie sie bspw. im Neighbor-Joining-Baum zu erkennen ist.




Abbildung 4: Phylogenetischer Baum erstellt mit der Neighbor-Joining-Methode

Primaten erscheinen als klar erkennbare gemeinsame Gruppe, innerhalb derer Menschenaffen und Altweltaffen näher zusammenliegen, während Neuweltaffen früher abzweigen. Auch Paarhufer und walverwandte Arten gruppieren sich konsistent zusammen, ebenso die Raubtiere als stabile gemeinsame Klade. UPGMA und WPGMA (siehe Anhang Abb. 7 und 8) zeigen im Vergleich zum Neighbor-Joining-Baum mehrere topologische Verschiebungen, auch wenn ihre Grundstruktur insgesamt ähnlich bleibt, was sich im geordneten Tanglegramm beider Methoden zeigt (vgl. Anhang Abb. 10). Ein Beispiel ist die unterschiedliche Position von *Equus caballus*: Im UPGMA-Baum steht das Pferd näher bei Raubtieren und Flossenfüßlern, im WPGMA-Baum dagegen eher bei Schwein, Wal und Wiederkäuern. Im Vergleich von UPGMA und Ward (s. Anhang Abb. 9) werden die Unterschiede noch deutlicher. Zwar stimmen die Hauptgruppierungen überein, in der feineren Verzweigungsstruktur weicht Ward aber stärker ab, etwa bei der Einbindung von *Otolemur* und *Daubentonia* innerhalb der Primaten sowie bei der engeren Schwestergruppenbildung von Wildschwein und Potwal (vgl. Anhang Abb. 11). Auch der Vergleich von NJ und WPGMA zeigt, dass die großen Kladen weitgehend erhalten bleiben obwohl

einzelne Feinstrukturen, wie etwa die Verzweigungsreihenfolge der Feuchtnasenprimaten, methodenabhängig variieren (vgl. Anhang Abb. 12). Diese Abweichungen sind jedoch angesichts der verletzten Ultrametrie-Annahme erwartbar.

4 Diskussion

4.1 Interpretation der Modellevaluation: Skalierung und Evolutionsmodell

Die Analyse der Divergenzskalierung zeigte, dass die Standardmatrix BLOSUM62 für die hochkonservierten Top-30-Hits ($> 85\%$ Identität) zu weich ist (Underfitting), während PAM30 Variationen übermäßig stark bestraft (Overfitting). Die geringste Abweichung (ΔH) in der erwarteten Entropie stellten hingegen auch bei einer Erweiterung auf größere Treffermengen (z. B. bis hin zu allen 501 Sequenzen) die PAM70 und BLOSUM90 Matrizen.

Da die Substitutionsmatrix auch eine implizite Biologische Annahme beinhaltet, sind die genauen Unterschiede der Entropie von PAM70 und BLOSUM90 gegenüber der Wahl des Evolutionsmodells zu vernachlässigen. Die anschließende Korrelationsanalyse der Zielhäufigkeiten konnte diesen relativen Gleichstand bei der Skalierung zugunsten des PAM-Modells brechen. Die Tatsache, dass PAM70 die Substitutionsmuster besser erklärt als BLOSUM90, lässt tiefgreifende Rückschlüsse auf die evolutionäre Dynamik von TSR3 zu. Während BLOSUM-Matrizen auf konservierten Sequenzblöcken (Domänen) basieren, modelliert PAM die Evolution als zeitkontinuierliche Punktmutationen (Markov Prozess). Der bessere Fit mit PAM ließe sich somit zum Beispiel durch die essentielle Rolle des TSR3 in der Ribosomenbiogenese oder mit einer allgemeinen Wichtigkeit der Struktur (z. B. durch Signalproteine) erklären. Eine reine Selbstkorrelation durch die Matrixwahl im ClustalW Algorithmus oder der BLAST Ergebnissen kann durch die angewandten Hypothesen in Tabelle 2 ausgeschlossen werden.

Besonders bemerkenswert und stützend für die Wahl von PAM70 ist das Verhalten des Modells bei einer Erweiterung der Datenbasis. Weitert man die Betrachtung von den eng verwandten Top-30-Hits auf die gesamte Datenbank ($N = 501$) aus, fällt relativ dazu die für kurze evolutionäre Distanzen ausgerichtete PAM30 wie erwartet ab und alle BLOSUM Modelle gewinnen dazu. Die Korrelation für PAM70 hingegen *verbessert* sich paradoxerweise sogar noch (von $R = 0,855$ auf $R = 0,876$). Damit ist empirisch gezeigt, dass PAM70 nicht nur lokal an die Top-30-Hits "overgefitet" ist, sondern eine allgemeingültige, robuste Matrix für die Modellierung der globalen Evolution von TSR3 darstellt.

Interessant ist dabei jedoch, dass wie in Abbildung 1 gezeigt vor allem Tyrosin austausche von der PAM70 schlecht eingeschätzt werden. Da die betroffenen Austausche keine Anomalie in dem Aminosäureprofil des TSR3 zeigen, ließe sich damit eine besondere Rolle des Tyrosin für die Struktur des Proteins ableiten. Die Schwäche in der Abbildung dieser Substitutionen gilt es für mögliche Folgeanalysen zumindest zu beachten.

4.2 Kritische Reflexion der Methodik und akademischen Praxis

Die empirische Evaluation der Substitutionsmatrizen wirft eine grundsätzliche wissenschaftstheoretische Frage auf, die auch die Formulierung der zugrunde liegenden Arbeitsanweisung berührt. Dort wird angegeben, dass es bezüglich der Matrixwahl keine eindeutige "*one is right everything else is wrong*"-Antwort gäbe.

Dieser Prämisse muss auf Basis der vorliegenden Datenlage widersprochen werden. Zwar ist es korrekt, dass evolutionäre Modelle grundsätzlich mathematische Approximationen darstellen und keine absolute biologische "Wahrheit" abbilden können. Dennoch zeigen die empirisch erhobenen Metriken, insbesondere die Diskrepanz in der relativen Entropie und die klaren Differenzen in der Korrelation der Zielhäufigkeiten, dass stochastische Verfahren sehr wohl in der Lage sind, eine quantifizierbare Hierarchisierung der Matrizen vorzunehmen. Im Kontext des Untersuchten TSR3 ist die Wahl von BLOSUM62 im Vergleich zu PAM70 empirisch schlichtweg suboptimal und mathematisch als schlechtere Passform zu bewerten.

Dieser Befund erzwingt eine kritische Auseinandersetzung mit der gängigen Praxis in weiten Teilen der biologischen Fachliteratur. Allzu oft wird BLAST als algorithmische "Black Box" betrachtet, bei der Standardeinstellungen (wie BLOSUM62) unreflektiert übernommen werden. Als Rechtfertigung dient hierbei häufig die pragmatische Annahme, die Wahl der Matrix verändere die resultierenden BLAST-Treffer im Zweifelsfall ohnehin nicht signifikant. Zum eine lässt sich so eine Implikation im Vorhinein einer Analyse nicht belegen, zum Anderen darf sie auch nicht als akademische Entschuldigung dafür dienen, sich der Evaluierung der Methodik zu entziehen. Die vorliegenden Daten widersprechen zudem jener Annahme: Selbst bei einem hochkonservierten Protein wie dem TSR3 führt der Wechsel von der Standardmatrix BLOSUM62 zu PAM70 bei 15 von 28 gemeinsamen Spezies zu einer relevanten Rangverschiebung. So rückt beispielsweise das Pferd (*Equus caballus*) von Rang 20 unter BLOSUM62 auf Platz 13 unter PAM70 vor. Unter PAM70 fallen ausserdem *Choloepus didactylus* (Zweizehen-Faultier) und *Felis catus* (Hauskatze) aus den Top30 und werden durch *Sciurus vulgaris* (Eichhörnchen) und *Physeter catodon* (Pottwal) ersetzt (nachzulesen in *Results_Blast* [4]). Für mögliche nachgelagerte Sequenzanalysen (z. B. der Distanz Mensch-Pferd) stellt eine solche Verschiebung einen gravierenden Unterschied dar.

Die Wahl der Matrix ist damit keine triviale Formalität, sondern definiert das stochastische Fundament, auf dem sämtliche Folgeanalysen – vom Multiplen Sequenzalignment bis zur Berechnung phylogenetischer Distanzmatrizen – aufbauen. Eine ungenaue oder unpassende Basis in der initialen Homologiesuche kompromittiert zwangsläufig die Trennschärfe, die Reproduzierbarkeit und damit letztlich die wissenschaftliche Aussagekraft der daraus erhobenen phylogenetischen Daten.

4.3 Methodenkritik: Performance des ClustalW-Algorithmus

Für das Multiple Sequence Alignment wurde der ClustalW-Algorithmus verwendet. Als progressiver Alignment-Algorithmus basiert ClustalW auf einer heuristischen Herangehensweise, bei der Sequenzen schrittweise entlang eines Guide-Trees aligniert werden. Ein systematischer Nachteil dieser Methodik ist das Prinzip „once a gap, always a gap“: Fehler, die in frühen Phasen des Alignments (bei der Ausrichtung nah verwandter Sequenzen) gemacht werden, können in späteren Schritten nicht mehr korrigiert werden.

Im vorliegenden Fall von TSR3 erweist sich diese methodische Schwäche jedoch als unproblematisch. Wie die Auswertung zeigt, besitzt das Protein mit der Ribosom-Biogenese-Domäne einen extrem hochkonservierten Kernbereich (> 95 %). Dieser Bereich fungiert während des progressiven Alignments als verlässlicher und stabiler struktureller „Anker“. Die eindeutige Zuordnung in dieser Region stabilisiert die globale Alignment-Matrix und minimiert die Fehlerfortpflanzung signifikant, sodass die Ergebnisse als äußerst valide betrachtet werden können.

4.4 Biologische Implikation: Die Rolle intrinsisch ungeordneter Regionen (IDRs)

Die Gegenüberstellung von Sequenzvariabilität und Strukturvorhersage hat die C- und N-terminale Region eindeutig als *Intrinsically Disordered Region* (IDR) identifiziert. Die hohe Toleranz für Aminosäuresubstitutionen und Indels (Gap-Rate von rund 22 %) sowie die fehlende definierte Tertiärstruktur (pLDDT < 50) dürfen jedoch keinesfalls als funktionelle Irrelevanz fehlinterpretiert werden.

Vielmehr erfüllen IDRs essenzielle biologische Aufgaben, die gerade von ihrer Flexibilität abhängen. Im zellulären Kontext könnten solche unstrukturierten Domänen als dynamische Bindungsstellen für Signalmoleküle oder als molekulare Interaktionszentren (Hubs) in hochkomplexen Protein-Netzwerken fungieren. Im Falle eines Ribosomen-Biogenese-Faktors wie TSR3 könnte dieser flexible Proteinabschnitt zwingend notwendig sein, um dynamisch mit anderen Reifungsfaktoren (wie beispielsweise der Kinase Rio2 [1]) oder dem räumlich ausgedehnten rRNA-Gerüst zu interagieren. Der evolutionäre Selektionsdruck wirkt in dieser Region folglich nicht auf den Erhalt einer starren 3D-Faltung, sondern auf die Bewahrung der physikalisch-

chemischen Flexibilität und spezifischer, kurzer Interaktionsmotive, die sich möglicherweise erst bei Bindung an ihren Interaktionspartner falten (Disorder-to-Order-Transition).

4.5 Phylogenetische Analyse der TSR3-Homologen

Die allgemein niedrige Distanzspanne aus der Heatmap deutet auf insgesamt hohe Konservierung des TSR3-Proteins hin. Zudem zeigt die rechnerischen Voranalysen, dass die Annahme strikter Ultrametrie nicht gestützt wird, was darauf hinweist, dass es keine global konstanten Evolutionsrate für TSR3 gibt. Gleichzeitig zeigen sowohl die Four-Point-Condition als auch der Delta-Plot, dass die Distanzmatrix insgesamt relativ klar baumartig strukturiert ist. Die wenigen Verletzungen dominieren die Gesamtstruktur dabei nicht.

Methodisch bedeutet das, dass nicht jede Clustering-Methode für diesen Datensatz gleich geeignet ist. UPGMA und WPGMA arbeiten unter der Voraussetzung einer Molekularen Uhr, welche aufgrund fehlender Ultrametrie nicht gegeben ist. Die Ward-Methode reagiert weniger direkt auf diese Annahme, bevorzugt jedoch kompakte Clusterstrukturen und ist damit ebenfalls nicht primär als phylogenetisches Rekonstruktionsverfahren konzipiert. Neighbor Joining ist unter diesen Bedingungen klar besser angepasst, weil das Verfahren ohne Ultrametrie auskommt und unterschiedliche Evolutionsraten zwischen Linien zulässt.

Die Baumwahl ergibt sich damit nicht nur aus biologischer Plausibilität, sondern auch unmittelbar aus den rechnerischen Eigenschaften der Distanzdaten. Die hohe cophenetische Korrelation des NJ-Baumes bestätigt, dass er die Struktur der ursprünglichen Distanzmatrix am besten wiedergibt. Dass jedoch keiner der Bäume als robust bewertet wurde zeigt, vor allem kurze interne Äste sind anfällig dafür, bei geringfügigen Distanzabweichungen ihre Position oder Verzweigungsreihenfolge zu verändern. Deshalb sollten die tieferen internen Aufspaltungen mit Vorsicht interpretiert werden.

Insgesamt zeigt sich damit ein klares Bild: die Hauptgruppen des Datensatzes bleiben in allen Verfahren weitgehend erhalten und sind stabil erkennbar, während die exakte Feinauflösung innerhalb dieser Gruppen nicht vollständig robust abgesichert ist.

Der Vergleich der verschiedenen Bäume unterstreicht diese Einschätzung zusätzlich. Einzelne Arten werden teilweise anders positioniert, als es nach den bekannten Verwandtschaftsverhältnissen zu erwarten wäre. Der NJ-Baum verbindet jedoch mathematische Passung und biologische Interpretierbarkeit in der überzeugendsten Weise und sollte daher als bevorzugte phylogenetische Rekonstruktion für die vorliegenden TSR3-Homologen interpretiert werden.

Die genauere Betrachtung des Neighbor-Joining-Baumes zeigt, die Primaten erscheinen als geschlossene Gruppe mit einer sinnvollen internen Staffelung. Menschenaffen und Altweltaffen liegen eng beieinander, während Neuweltaffen früher abzweigen. Diese Struktur entspricht den etablierten Verwandtschaftsverhältnissen innerhalb der Primaten [5]. Auch die gemeinsame Gruppierung von Paarhufern und walverwandten Arten ist von besonderem Interesse, da sie die bekannte Einordnung innerhalb der Cetartiodactyla widerspiegelt [6]. Die Raubtiere bilden ebenfalls eine konsistente Gruppe was gut mit bereits veröffentlichten Ergebnissen übereinstimmt [7]. Dass einzelne Arten, etwa das Pferd, randständiger positioniert erscheinen, fügt sich dabei bereits in die Beobachtungen aus der Heatmap ein und deutet auf Unstimmigkeiten hin [8], welche sich eventuell durch den Vergleich mit mehr als 30 Arten ausbessern würde.

Literatur

- [1] B. Meyer u. a., "Ribosome biogenesis factor Tsr3 is the aminocarboxypropyl transferase responsible for 18S rRNA hypermodification in yeast and humans", *Nucleic Acids Research*, Jg. 44, Nr. 9, S. 4304–4316, 19. Mai 2016, ISSN: 0305-1048. DOI: 10.1093/nar/gkw244. besucht am 8. Jan. 2026. Adresse: <https://doi.org/10.1093/nar/gkw244>.
- [2] S. F. Altschul und W. Gish, "Local alignment statistics", *Methods in Enzymology*, Jg. 266, S. 460–480, 1996, ISSN: 0076-6879. DOI: 10.1016/s0076-6879(96)66029-7.
- [3] "UniProt eintrag des TSR3 human", UniProt, besucht am 31. Dez. 2025. Adresse: <https://www.uniprot.org/uniprotkb/Q9UJK0/entry#sequences>.
- [4] J. Rasp, J. Vogel und R. Ortner, *Code+Ergebnisse:Projektarbeit_genomanalysen-und-phylogenie*, original-date: 2026-01-06T19:20:47Z, 9. Apr. 2026. besucht am 10. Apr. 2026. Adresse: https://github.com/JulianR101100/Projektarbeit_genomanalysen-und-phylogenie.
- [5] L. Pozzi, J. A. Hodgson, A. S. Burrell, K. N. Sterner, R. L. Raaum und T. R. Disotell, "Primate phylogenetic relationships and divergence dates inferred from complete mitochondrial genomes", *Molecular Phylogenetics and Evolution*, Jg. 75, S. 165–183, 2014.
- [6] A. Poor. "Cetartiodactyla (cetaceans and artiodactyls)", Animal Diversity Web, University of Michigan Museum of Zoology, besucht am März 2026.
- [7] J. W. Higdson, O. R. P. Bininda-Emonds, R. M. D. Beck und S. H. Ferguson, "Phylogeny and divergence of the pinnipeds (Carnivora: Mammalia) assessed using a multigene dataset", *BMC Evolutionary Biology*, Jg. 7, S. 216, 2007.
- [8] P. Myers. "Perissodactyla (horses, rhinoceroses, and tapirs)", Animal Diversity Web, University of Michigan Museum of Zoology, besucht am März 2026.

Link zu Git Hub Repository der Projektarbeit [4]. Mit KI Erstellte Inhalte (ChatGPT-5 und GEMINI3) sind in Kommentaren gekennzeichnet. Unter die Bearbeitung viel auch die grafische Anpassung von Plots.

Letzter Commit vor Abgabe: 2316128 (Weitere Kennzeichnungen von KI Inhalten)

5 Anhang

5.1 Farbkodierung und Histogramm der Heatmap




Abbildung 5: Farbkodierung und Histogramm der Distanzen in der Heatmap

5.2 Überprüfung der Ultrametrie und Four-Point-Condition mit allen getesteten Toleranzen

Toleranz	Verletzungen strikt	Verletzungsrate strikt	Verletzungen nicht-strikt	Verletzungsrate nicht-strikt
0.1	11	0.27%	0	0%
0.03	240	5.91%	230	5.67%
0.02	713	17.56%	703	17.32%
0.01	1883	46.38%	1875	46.18%
0.005	2940	72.41%	2934	72.27%
0.001	3818	94.04%	3818	94.04%

Tabelle 5: Ergebnisse des Ultrametrie-Tests mit allen getesteten Toleranzen

Toleranz	Verletzungen	Verletzungsrate
0.01	9307	33.96%
0.02	2741	10.00%
0.04	364	1.33%
0.06	63	0.23%
0.1	0	0%
0.2	0	0%

Tabelle 6: Ergebnisse des Four-Point-Condition-Tests mit allen getesteten Toleranzen

5.3 Delta-Plot




Abbildung 6: Darstellung der Ergebnisse des Delta-Plots zur validierung der four point condition

5.4 Werte für Robustheit und cophenetische Korrelation

Methode	Robust	est_ratio	max_dist	w0	Cophenetische Korrelation
WPGMA	FALSE	27.1788	0.058593	0.002156	0.949885
NJ	FALSE	37.1081	0.043573	0.001174	0.976927
UPGMA	FALSE	42.3827	0.063070	0.001488	0.951068
WARD	FALSE	99.1251	0.313291	0.003161	0.854188

Tabelle 7: Robustheit und cophenetische Korrelation der Rekonstruktionsmethoden

5.5 Phylogenetische Bäume verschiedener Clustering Methoden

5.5.1 UPGMA



Abbildung 7: Phylogenetischer Baum erstellt mit UPGMA

5.5.2 WPGMA





Abbildung 8: Phylogenetischer Baum erstellt mit WPGMA

5.5.3 WARD



Abbildung 9: Phylogenetischer Baum erstellt mit WARD

5.5.4 Visueller Vergleich ausgewählter Methoden



(a) Vergleich UPGMA und WPGMA im Tanglegram


UPGMA:

WPGMA:




(b) Vergleich UPGMA und WPGMA im Tanglegram (im Detail)

Abbildung 10: Vergleich UPGMA und WPGMA im Tanglegram mit Detailansicht




(a) Vergleich UPGMA und WARD im Tanglegram



(b) Vergleich UPGMA und WARD im Tanglegram (im Detail)

Abbildung 11: Vergleich UPGMA und WARD im Tanglegram mit Detailansicht


NJ vs WPGMA



(a) visueller Vergleich NJ und WPGMA

NJ

WPGMA



(b) visueller Vergleich NJ und WPGMA (im Detail)

Abbildung 12: visueller Vergleich NJ und WPGMA mit Detailansicht