GuP Phylo Baum Aufgaben (grobe Auswertung)

Johann Vogel

March 2026

1 Vergleich der Bäume: UPGMA, WPGMA, WARD und Neighbor-Joining (NJ)

1.1 Gemeinsame, stabile Muster (alle Methoden)

In allen vier rekonstruierten Bäumen (UPGMA, WPGMA, WARD und NJ) sind sehr ähnliche "grobe" Gruppen erkennbar. Diese entsprechen weitgehend bekannten Großkladen der Säugerphylogenie:

- **Primaten (Haplorhini):** *Homo*, *Macaca*, *Rhinopithecus*, *Pongo*, *Nomascus*, *Ateles*, *Aotus*, *Callithrix*.
- **Feuchtnasenprimaten / Prosimians (Strepsirrhini + Tarsier):** *Microcebus*, *Cheirogaleus*, *Lemur*, *Daubentonia*, *Otolemur*, *Carlito*.
- **Rodentia (Nagetiere):** *Sciurus*, *Ictidomys*; *Castor* wird häufig als separater Ausreißer-Cluster abgespalten.
- **Carnivora / Pinnipedia:** *Ursus*, *Gulo*, *Enhydra*, *Zalophus*, *Leptonychotes*.
- **(C)etartiodactyla:** *Bos*, *Bubalus*, *Cervus*, *Ovis*, *Capra*, *Sus*, *Physeter*.

Diese Gruppierungen sind konsistent mit dem, was man für große Säuger-Kladen in der Literatur erwartet (u. a. Primaten, Rodentia, Carnivora und Cetartiodactyla).

1.2 Unterschiede zwischen den Algorithmen

UPGMA/WPGMA. UPGMA und WPGMA liefern **equidistante (ultrametrische), gerootete** Bäume und entsprechen damit dem klassischen *molekulare-Uhr*-Modell. Das führt zu übersichtlichen Bäumen, setzt jedoch voraus, dass die zugrunde liegende Distanzmatrix (annähernd) ultrametrisch ist (vgl. Vorlesung 9; UPGMA-Annahme "molecular clock").

WARD. Ward (`ward.D2`) ist ein Clustering-Kriterium aus der Statistik und optimiert eine Varianz-/SSE-ähnliche Zielgröße. Es ist sehr gut geeignet als allgemeines Clusterverfahren, ist jedoch **nicht primär als phylogenetisches Rekonstruktionsmodell** konzipiert. In der Praxis treten bei Ward-Bäumen häufiger Artefakte wie extrem kurze oder sogar praktisch null-lange Kanten auf (in den Plots z. B. als "gepunktete" Segmente sichtbar). In Vorlesung 9 wird Ward entsprechend eher als alternatives Linkage-Kriterium diskutiert und nicht als Standard-Phylogenie-Rekonstruktor.

Neighbor-Joining (NJ). Neighbor-Joining ist ein **distanzbasiertes phylogenetisches Verfahren**, das **keine Ultrametrie** voraussetzt und gezielt für *tree-like*/additive Distanzdaten entwickelt wurde (vgl. Vorlesung 10; Saitou & Nei, 1987).

2 Welcher Algorithmus passt zur Forschungsfrage (TSR3)?

Für TSR3 ist die zentrale Aufgabe: *Aus einer Distanzmatrix (aus dem MSA) einen gut begründeten phylogenetischen Baum rekonstruieren und bewerten.* Dazu sind insbesondere zwei Eigenschaften entscheidend: **(A) Ultrametrie** und **(B) Additivität**.

2.1 (A) Ultrametrie (relevant für UPGMA/WPGMA)

Die Ultrametrie wurde systematisch über verschiedene Toleranzen geprüft. Die Ergebnisse zeigen eine starke Abhängigkeit von der Wahl der Toleranz:

- bei `tol` $= 0.1$ nahezu ultrametrisch (strict: 0.27% Violations; non-strict: 0%),
- bei `tol` $= 0.03$ bereits $\sim 6\%$ Violations,
- bei `tol` $= 0.02 \sim 17\%$ Violations,
- bei `tol` $= 0.01 \sim 46\%$ Violations,
- bei `tol` $= 0.001 \sim 94\%$ Violations.

Damit ist Ultrametrie **nicht robust/stabil** erfüllt, sondern hängt stark von einem relativ großzügigen Toleranzniveau ab. Folglich ist das equidistante "molekulare Uhr"-Modell, auf das UPGMA/WPGMA aufbauen, für diesen Datensatz **nicht sauber abgesichert**. Diese starke Toleranzabhängigkeit ist ein typisches Warnsignal: UPGMA kann nur dann als phylogenetisch gut begründetes Modell gelten, wenn Ultrametrie plausibel ist.

2.2 (B) Additivität / Four-Point Condition (relevant für NJ)

Die HTML-Solution erläutert: Wenn die (strict) **Four-Point Condition** (nahezu) erfüllt ist, sind Distanzen **tree-like/additiv** und eine distanzbasierte Rekonstruktion ist gut begründbar (Tree-Metric-Theorem; Vorlesung 10). Die Ergebnisse zeigen:

- bei `tol` $= 0.04$ nur 1.33% Violations,
- bei `tol` $= 0.06$ nur 0.23% Violations,
- bei `tol` $= 0.1$ 0% Violations (Additivität `TRUE`).

Das spricht dafür, dass die Distanzmatrix **weitgehend tree-like** ist, sobald ein realistischer Mess-/MSA-Spielraum zugelassen wird. Genau in dieser Situation ist NJ typischerweise sehr geeignet.

Literaturbezug. NJ wurde als Distanzmethode für phylogenetische Rekonstruktion aus Distanzdaten eingeführt (Saitou & Nei, 1987) und ist bis heute ein Standardverfahren. BioNJ (Gascuel, 1997) ist eine bekannte Verbesserung für verrauschte Distanzschätzer.

Kurzfazit.

- Wenn Ultrametrie nicht stabil ist $\Rightarrow$ UPGMA/WPGMA als "Uhr-Phylogenie" fraglich.
- Wenn Additivität relativ gut ist $\Rightarrow$ NJ ist das passendere phylogenetische Modell.

3 Fit/Qualität: Cophenetic-Correlation und Robustheit

3.1 Cophenetic correlation (Fit Baum ↔ Distanzmatrix)

Die cophenetic correlation misst, wie gut die im Baum implizierten Distanzen die ursprünglichen Distanzen reproduzieren (lineare Übereinstimmung). Die Werte sind:

- NJ: 0.9769 (beste Übereinstimmung),
- UPGMA: 0.9620,
- WPGMA: 0.9592,
- WARD: 0.8495.

Damit reproduziert NJ die ursprünglichen Paar-Distanzen am besten. Die HTML-Solution nutzt genau diese Idee (Baumdistanz vs. Originaldistanz) zur Bewertung.

3.2 Robustheit (Safety-Radius-Idee aus VL09)

In Vorlesung 9 wird Robustheit über die maximale Abweichung

$$\|M' - M\|_\infty$$

und die kleinste interne Kante w_0 diskutiert. Daraus ergibt sich eine Safety-Radius-Logik (Theorem 9.11), u. a. mit $\rho = 1$ für UPGMA/WPGMA unter Equidistanz-Annahme und $\rho = \frac{1}{2}$ für NJ.

In den Ergebnissen ist bei einheitlicher Wahl $\rho = 0.5$ für alle Methoden:

- `truth` ist für alle Bäume `FALSE`,
- `est_ratio` ist sehr groß (WPGMA ~ 27, NJ ~ 37, UPGMA ~ 42, WARD ~ 99).

Das bedeutet: **Kein Baum ist formell robust** nach diesem strengen Kriterium. Das passt dazu, dass die Daten weder perfekt ultrametrisch noch perfekt additiv sind und zudem w_0 sehr klein ist (eine potenziell instabile interne Kante). Wichtig: "nicht robust" heißt nicht automatisch "falsch", sondern: **keine Garantie**; daher ist eine vorsichtige Interpretation notwendig.

Umgang damit. Robustheit dient hier als Warnlampe (keine Garantie), während für die Modellwahl stärker auf Fit (correlation) und Modellannahmen (Ultrametrie/Additivität) abgestellt wird.

4 Schlussfolgerung: Welchen Baum wählen?

Ich würde **NJ als Hauptbaum** verwenden und UPGMA/WPGMA als Vergleich (Clustering-/Uhr-Modell) ergänzen. Begründung: Die Daten sind **nicht stabil ultrametrisch** (UPGMA/WPGMA-Annahme unsicher), aber **weitgehend tree-like/additiv** (Four-Point Condition bei moderater Toleranz nahezu erfüllt) und NJ zeigt den **besten Fit** (höchste cophenetic correlation).

5 Überlappung mit publizierten Resultaten

Auf der Ebene der großen Säugerkladen stimmen die rekonstruierten Gruppen mit etablierten Ergebnissen der molekularen Säugerphylogenie überein:

- Primaten als Gruppe,

- Rodentia als Gruppe,
- Carnivora/Pinnipedia als Gruppe,
- Cetartiodactyla als Gruppe (inkl. Cetacea).

Nicht perfekte Platzierungen einzelner Taxa (z. B. *Castor* als Rodentia-Ausreißer oder *Equus* gemischt mit anderen Blöcken) sind plausibel durch Marker-/Modell-/MSA-Limitationen erklärbar und nicht zwingend "Biologie".

6 Limitationen und Future Work

6.1 Limitationen

- **Sehr simples Distanzmodell:** Identity-basierte Distanzen (auch quadriert) korrigieren nicht für Mehrfachsubstitutionen oder Rate-Heterogenität. Für Proteine wären modellbasierte Distanzen (z. B. JTT/WAG) plausibel.
- **Nur distanzbasierte Rekonstruktion:** ML/Bayes-Verfahren liefern bei schwierigen Datensätzen oft robustere Topologien, benötigen aber mehr Rechenzeit und Modellannahmen.
- **MSA- und Trimming-Effekte:** Fehlalignierte Regionen und Gaps können Distanzen verzerren und Ausreißercluster begünstigen (z. B. *Castor*).
- **Robustheit:** Safety-Radius-Test ergibt überall `FALSE`; daher keine formale Garantie, sondern vorsichtige Interpretation.

6.2 Was ich mit mehr Zeit/Daten anders machen würde

- **Bootstrap** über Alignment-Spalten zur Abschätzung von Knotensupport.
- **Besseres Distanzmodell** oder direkt **ML-Baum** aus dem Alignment.
- **Mehr Taxa und Outgroup:** verbessert Stabilität und ermöglicht biologisch interpretierbares Rooting.
- **Vergleich mit Referenzphylogenie:** z. B. über NCBI-Taxonomie oder publizierte Säuger-Superbäume sowie quantitative Baumdistanz (z. B. Robinson–Foulds).
- **BioNJ** als Alternative zu NJ bei verrauschten Distanzschätzern (Gascuel, 1997).

7 Robustheit (VL09) – Diskussion der Ergebnisse

Vorlesung 9 definiert Robustheit über $\|M' - M\|_\infty$ und w_0 und diskutiert die Safety-Radius-Idee (Theorem 9.11). Das Ergebnis `truth=FALSE` bei $\rho = 0.5$ bedeutet:

- Die Abweichung zwischen Baum-implizierten Distanzen und Originaldistanzen ist im Verhältnis zur kleinsten internen Kante zu groß, um eine Garantie zu geben.
- Praktisch können einzelne Splits instabil sein.
- Dennoch sprechen Fit (cophenetic correlation) und inhaltliche Plausibilität klar für NJ als bestes Modell für diesen Datensatz.

8 Endfazit

- **Beobachtung:** große Säugerkladen werden konsistent gruppiert; Ultrametrie ist nicht stabil; Additivität ist bei moderater Toleranz gut; NJ passt die Distanzen am besten.
- **Schlussfolgerung:** NJ als Hauptbaum; UPGMA/WPGMA als Vergleich/Clustering; Ward eher als Cluster-Alternative.
- **Literatur-Überlappung:** Grobe Kladen stimmen mit publizierten Säugerphylogenien überein; Abweichungen einzelner Taxa sind plausibel durch Marker-/Modell-/MSA-Limitationen.